Day2 실습 — 부동산 가격 결정요인 회귀분석

UCI Real Estate Valuation Dataset · Baseline → 잔차진단 → 변수변환 → 변수선택

SKALA · 데이터 분석 및 AIOps
광주 1반 · **서혁인** · 담당교수 박병선
작성일 **2026-07-28**

1 Baseline 적합 → 2 잔차진단 (4대 가정) → 3 Task2 로그변환 → 4 Task3 변수선택 → 5 최종 모델

부동산 414건의 실거래가를 6개 변수로 설명하는 OLS 회귀모델을 구축했다. Baseline(R^2=0.558) → 로그변환(R^2=0.634) → 변수선택(Adj.R^2=0.628)의 단계를 거쳐 **변수는 1개 줄이면서 설명력은 오히려 높인** 최종 모델을 도출했다.

01 · EDA 요약

상관관계 (price 기준)

- `dist_to_mrt` r=−0.674 (최강)
- `n_convenience` r=0.571
- `latitude` r=0.546 · `longitude` r=0.523
- `house_age` r=−0.211
- `transaction_date` r=0.087 (거의 무관)

분포 · 비선형성

- `dist_to_mrt` skew=1.89 (최대 치우침)
- 산점도+LOESS: `dist_to_mrt` 단조 감쇠 곡선
- `house_age` 는 U자형 비단조 곡률
- price 자체도 고가 이상치 존재

2차항 vs 로그 (quad_gain / log_gain)

- `dist_to_mrt` : 0.073 / 0.044 → 로그 적합
- `house_age` : 0.157 / 0.066 → 2차항 적합(제외)
- 나머지 변수는 비선형성 미미

02 · 모델 단계별 비교

지표	① BASELINE (6개)	② 로그변환	③ 최종 (−LONGITUDE, 5개)
R^2	0.558	0.634	**0.634**
Adjusted R^2	0.550	0.627	**0.628**
Train / Test RMSE	9.117 / 7.315	8.298 / 6.779	8.298 / 6.779
Prob(F-statistic)	1.46e-54	1.09e-67	9.82e-69
Breusch-Pagan p	0.209	0.131	—
최대 P>|t|	**`longitude` 0.599**	**`longitude` 0.887**	**`n_conv.` 0.142** 유지

03 · 최종 모델 회귀계수 (5변수)

변수	계수	표준오차	T값	P>|T|
const	−19,700.0	3,446.5	−5.72	0.000
`transaction_date`	6.320	1.647	3.84	0.000
`house_age`	−0.242	0.041	−5.89	0.000
`dist_to_mrt` (log1p)	−7.051	0.602	−11.72	0.000
`n_convenience`	0.324	0.220	1.47	0.142 유지
`latitude`	**282.784**	**42.176**	**6.71**	**0.000**

모델 진단 메모

- Adjusted R^2=0.628, Prob(F-statistic)=9.82e-69 — 모델 전체 유의
- Cond. No.=1.51e+07 — 좌표형 변수(latitude 등) 스케일 차로 인한 다중공선성 경고는 여전히 존재
- `n_convenience` 는 p>0.05지만 계수 부호·크기가 baseline과 일관 — 다중공선성으로 해석해 유지

04 · 잔차진단 — 선형모형 4대 가정 체크

가정	진단 지표	BASELINE	최종 모델	판정
선형성	잔차 vs `dist_to_mrt`	곡선 패턴	로그변환 후 완화	개선
독립성	Durbin-Watson	1.923	2.033	문제없음
등분산성	Breusch-Pagan p	0.209	0.131	문제없음
정규성	**Skew / Kurtosis**	**2.14 / 17.3**	**2.35 / 19.9**	위배

해석

- 선형성·독립성·등분산성은 문제없거나 개선됨
- 정규성만 유일하게 위배 — 소수 초고가 매물(이상치)이 원인으로 추정
- 변수 변환만으로는 해소 불가 → 강건회귀·이상치 처리가 다음 과제

핵심 발견

1. **비선형성 교정 효과가 최대.** `dist_to_mrt` 로그변환만으로 R^2 7.6%p 상승(0.558→0.634).
2. **다중공선성의 함정.** 로그변환 후 `n_convenience` p-value 0.144로 급등했지만, 제거 시 Adj.R^2 하락 → 표준오차만 부풀려진 것으로 판단, 유지.
3. **유의성 ≠ 효과크기.** `longitude` 는 제거 시 Adj.R^2가 오히려 상승(0.6271→0.6282) — 진짜 무의미 변수.
4. 정규성(Skew 2.14·Kurtosis 17.3)은 위배되나 등분산성(BP p=0.209)·독립성(DW 1.923)은 문제없음.

결론 및 시사점

1. 최종 모델(5변수, Adj.R^2=0.628)은 `transaction_date, house_age, dist_to_mrt, n_convenience, latitude` 로 구성.
2. p-value만으로 변수를 제거하면 `n_convenience` 처럼 실제 설명력 있는 변수를 잃을 위험 — 제거 전 Adj.R^2 변화 필수 확인.
3. 잔차 곡선 패턴이 변환 대상 선정에 가장 직접적인 신호이며, skewness만으로는 `house_age` 형 비단조 관계를 놓칠 수 있음.
4. 남은 이상치·정규성 문제는 강건회귀(robust regression) 등 후속 과제로 남음.

종합 결론 — Baseline 대비 변수 1개(`longitude`) 감소, Adjusted R^2 0.550 → 0.628 (+7.8%p) 개선. 비선형 변환과 다중공선성 인지가 개선의 핵심이었다.

데이터: UCI Real Estate Valuation Data Set (id=477, n=414)

실습 파일: 실습_LinearRegression.ipynb